

Pesquisa e Dicionário de Features NIDS

CIC-IDS2017, CSE-CIC-IDS2018 e LycoS-Unicas-IDS2018
Subsídio para definição do schema canônico e da DSL UniQL

Objetivo. Catalogar sistematicamente as features presentes nos três samples, relacionar nomenclaturas equivalentes, registrar significado/unidade, estimar a presença entre as bases e propor uma decisão inicial para o schema canônico. As decisões são provisórias e devem ser validadas por profiling nos datasets completos e por experimentos de ablação quando indicado.

Importante. O dicionário possui 83 linhas conceituais, embora os samples tenham 79, 80 e 78 colunas. Isso ocorre porque o relatório representa a união semântica dos três schemas, inclui campos presentes em apenas uma ou duas bases e registra separadamente a duplicata conhecida de Fwd Header Length do CIC-IDS2017.

Classificação	Quantidade	Interpretação
KEEP_CORE	39	Núcleo obrigatório proposto.
KEEP_OPTIONAL	18	Disponível no schema, mas não obrigatória; frequentemente pede ablação.
DERIVE	6	Recalcular após harmonização.
INVESTIGATE	14	Exige evidência adicional.
DROP	5	Excluir do schema preditivo v0.1.
TARGET	1	Variável-alvo.

1. Fichas técnicas das bases

Dataset	Estrutura analisada	Extrator	Ambiente	Relação entre bases	Pontos de atenção	Fontes
CIC-IDS2017	8 CSVs MachineLearningCVE; sample com 79 colunas (1 duplicada), 78 conceitos após remover duplicata	CICFlowMeter	5 dias de tráfego benigno + ataques em ambiente controlado	Base CIC original; LycoS-IDS2017 foi reconstruído dos mesmos PCAPs com LycoSTand	Duplicações e outros problemas de extração/rotulagem documentados; forte risco de leakage com identificadores e timestamp.	S1; S2; S4; S6; S12
CSE-CIC-IDS2018	10 CSVs no conjunto local; sample com 80 colunas; variantes internas podem incluir Flow ID/Src IP/Src Port/Dst IP	CICFlowMeter-V3	AWS; 5 departamentos, 420 máquinas e 30 servidores; vários dias de ataques	É a fonte de PCAPs usada para gerar LycoS-Unicas-IDS2018	Cabeçalhos repetidos em alguns CSVs; schema varia entre arquivos; Protocol/Timestamp não existem no sample CIC17.	S3; S6; S7; S12
LycoS-Unicas-IDS2018	1 CSV; 13,691,268 registros; 77 features + label (78 colunas)	LycoSTand	Reextração dos PCAPs do CSE-CIC-IDS2018	Mesmo tráfego bruto do CSE-CIC-IDS2018, mas com extrator diferente; excelente para estudar efeito do extrator, não é ambiente totalmente independente	Não confundir cross-extractor com cross-environment; possui features adicionais de header mínimo/non-empty packets.	S4; S5; S6; S7; S10; S12; S13

Leitura metodológica. CSE-CIC-IDS2018 e LycoS-Unicas-IDS2018 compartilham os PCAPs de origem; a comparação entre eles é particularmente útil para estudar o efeito do extrator (CICFlowMeter-V3 vs. LycoSTand), mas não deve ser interpretada como um teste entre ambientes totalmente independentes.

2. Legenda de decisões e termos

Termo	Definição
KEEP_CORE	Entrar no núcleo obrigatório do schema canônico v0.1.
KEEP_OPTIONAL	Manter como feature padronizada opcional. O modelo pode usá-la ou não; ablação é recomendada em vários casos.
DERIVE	Não confiar prioritariamente no valor pré-calculado de cada extrator; recalcular com regra única após harmonização.
INVESTIGATE	A equivalência/necessidade ainda não está suficientemente estabelecida; exige profiling, inspeção de código, correlação/equality check ou ablação.
DROP	Excluir do schema preditivo v0.1. Pode ser metadado, duplicata ou feature com alto risco de leakage.
TARGET	Rótulo a ser harmonizado separadamente; nunca entra como feature de entrada X.
ABLAÇÃO	Experimento controlado: mesmo pipeline/modelo com e sem a feature ou grupo para medir impacto real.
SHORTCUT / LEAKAGE	Atalho específico do dataset que permite prever a classe sem aprender o comportamento de rede que deveria transferir para outros ambientes.
DERIVAÇÃO	Cálculo de uma feature a partir de outras, por exemplo pacotes/s a partir de contagem de pacotes e duração.

3. Primeira proposta de schema canônico v0.1

A proposta separa representação canônica de feature set do modelo. Uma feature KEEP_OPTIONAL pode existir no dataset harmonizado sem necessariamente ser entregue ao modelo. Esse desenho evita confundir padronização de dados com seleção de features.

3.1 Núcleo obrigatório

Atividade / ociosidade: active_mean, active_std, active_max, active_min, idle_mean, idle_std, idle_max, idle_min

Duração do fluxo: flow_duration

Tamanho de pacotes: fwd_pkt_len_max, fwd_pkt_len_min, fwd_pkt_len_mean, fwd_pkt_len_std, bwd_pkt_len_max, bwd_pkt_len_min, bwd_pkt_len_mean, bwd_pkt_len_std, pkt_len_min, pkt_len_max, pkt_len_mean, pkt_len_std

Temporização / IAT: iat_mean, iat_std, iat_max, iat_min, fwd_iat_total, fwd_iat_mean, fwd_iat_std, fwd_iat_max, fwd_iat_min, bwd_iat_total, bwd_iat_mean, bwd_iat_std, bwd_iat_max, bwd_iat_min

Volume do fluxo: fwd_pkt_count, bwd_pkt_count, fwd_bytes_total, bwd_bytes_total

3.2 Features opcionais

Cabeçalhos: fwd_header_len_total, bwd_header_len_total

Flags TCP: fwd_flag_psh, bwd_flag_psh, fwd_flag_urg, bwd_flag_urg, flag_fin, flag_syn, flag_rst, flag_psh, flag_ack, flag_urg, flag_cwe, flag_ece

Identificação / L3-L4: ip_protocol

Identificação / L4: dst_port

Janela TCP: fwd_tcp_init_win_bytes, bwd_tcp_init_win_bytes

3.3 Features derivadas

Razões: down_up_ratio

Tamanho de pacotes: pkt_len_var

Taxas: flow_bytes_per_s, flow_packets_per_s, fwd_packets_per_s, bwd_packets_per_s

3.4 Features ainda em investigação

Bulk: fwd_bulk_bytes_mean, fwd_bulk_pkt_mean, fwd_bulk_rate_mean, bwd_bulk_bytes_mean, bwd_bulk_pkt_mean, bwd_bulk_rate_mean

Cabeçalhos: bwd_header_len_min

Subflow: fwd_subflow_pkt_mean, fwd_subflow_bytes_mean, bwd_subflow_pkt_mean, bwd_subflow_bytes_mean

TCP / payload e segmento: fwd_non_empty_pkt_count, fwd_segment_size_min, bwd_non_empty_pkt_count

3.5 Exclusões propostas

Metadado temporal: timestamp

Qualidade de dados: fwd_header_len_duplicate_raw

Tamanho de pacotes: avg_packet_size, fwd_segment_size_avg, bwd_segment_size_avg

4. Dicionário completo das features

As tabelas seguintes são agrupadas por função. A coluna 'Nº' representa em quantas das três bases o conceito possui uma coluna correspondente (considerando equivalências semânticas provisórias). Para detalhes extensos como derivação, problemas conhecidos e IDs de fontes, consulte a planilha XLSX que acompanha este PDF.

Identificação / L4

Canonical	CIC17	CSE18	LycoS18	Nº	Unidade	Decisão	Significado e justificativa
dst_port	Destination Port	Dst Port	dst_port	3	porta L4 (0-65535)	KEEP_OPTIONAL	Porta de destino da camada de transporte (L4) do fluxo. É informação legítima do serviço de destino e aparece nas três bases, mas pode funcionar como atalho específico do cenário/ataque; não deve ser assumida como universal.

Identificação / L3-L4

Canonical	CIC17	CSE18	LycoS18	Nº	Unidade	Decisão	Significado e justificativa
ip_protocol	—	Protocol	ip_prot	2	IANA protocol number	KEEP_OPTIONAL	Número identificador do protocolo IP (por exemplo TCP=6, UDP=17). Pode diferenciar famílias de tráfego e existe em CSE/LycoS, mas não está no sample MachineLearningCVE do CIC17; portanto não pode compor o núcleo obrigatório dos três sem imputação/derivação externa.

Metadado temporal

Canonical	CIC17	CSE18	LycoS18	Nº	Unidade	Decisão	Significado e justificativa
timestamp	—	Timestamp	—	1	datetime	DROP	Instante de captura/início do fluxo. É metadado específico da captura e pode vaziar agenda de ataques/dias, criando atalho fortemente dependente do dataset; não deve ser feature do modelo cross-dataset.

Duração do fluxo

Canonical	CIC17	CSE18	LycoS18	Nº	Unidade	Decisão	Significado e justificativa
flow_duration	Flow Duration	Flow Duration	flow_duration	3	µs (CIC; validar LycoSTand)	KEEP_CORE	Duração total do fluxo. Feature comportamental de fluxo comum/compatível entre os datasets; preserva informação potencialmente transferível sem identificar diretamente o ambiente.

Volume do fluxo

Canonical	CIC17	CSE18	LycoS18	Nº	Unidade	Decisão	Significado e justificativa
fwd_pkt_count	Total Fwd Packets	Tot Fwd Pkts	fwd_pkt_cnt	3	contagem	KEEP_CORE	Número total de pacotes na direção forward. Feature comportamental de fluxo comum/compatível entre os datasets; preserva informação potencialmente transferível sem identificar diretamente o ambiente.
bwd_pkt_count	Total Backward Packets	Tot Bwd Pkts	bwd_pkt_cnt	3	contagem	KEEP_CORE	Número total de pacotes na direção backward. Feature comportamental de fluxo comum/compatível entre os datasets; preserva informação potencialmente transferível sem identificar diretamente o ambiente.
fwd_bytes_total	Total Length of Fwd Packets	TotLen Fwd Pkts	fwd_pkt_len_tot	3	bytes	KEEP_CORE	Soma dos tamanhos dos pacotes na direção forward. Feature comportamental de fluxo comum/compatível entre os datasets; preserva informação potencialmente transferível sem identificar diretamente o ambiente.
bwd_bytes_total	Total Length of Bwd Packets	TotLen Bwd Pkts	bwd_pkt_len_tot	3	bytes	KEEP_CORE	Soma dos tamanhos dos pacotes na direção backward. Feature comportamental de fluxo comum/compatível entre os datasets; preserva informação potencialmente transferível sem identificar diretamente o ambiente.

Tamanho de pacotes

Canonical	CIC17	CSE18	LycoS18	Nº	Unidade	Decisão	Significado e justificativa
fwd_pkt_len_max	Fwd Packet Length Max	Fwd Pkt Len Max	fwd_pkt_len_max	3	bytes	KEEP_CORE	Maior tamanho de pacote observado na direção forward. Feature comportamental de fluxo comum/compatível entre os datasets; preserva informação potencialmente transferível sem identificar diretamente o ambiente.

Canonical	CIC17	CSE18	LycoS18	Nº	Unidade	Decisão	Significado e justificativa
fwd_pkt_len_min	Fwd Packet Length Min	Fwd Pkt Len Min	fwd_pkt_len_min	3	bytes	KEEP_CORE	Menor tamanho de pacote observado na direção forward. Feature comportamental de fluxo comum/compatível entre os datasets; preserva informação potencialmente transferível sem identificar diretamente o ambiente.
fwd_pkt_len_mean	Fwd Packet Length Mean	Fwd Pkt Len Mean	fwd_pkt_len_mean	3	bytes	KEEP_CORE	Média do tamanho dos pacotes na direção forward. Feature comportamental de fluxo comum/compatível entre os datasets; preserva informação potencialmente transferível sem identificar diretamente o ambiente.
fwd_pkt_len_std	Fwd Packet Length Std	Fwd Pkt Len Std	fwd_pkt_len_std	3	bytes	KEEP_CORE	Desvio-padrão do tamanho dos pacotes na direção forward. Feature comportamental de fluxo comum/compatível entre os datasets; preserva informação potencialmente transferível sem identificar diretamente o ambiente.
bwd_pkt_len_max	Bwd Packet Length Max	Bwd Pkt Len Max	bwd_pkt_len_max	3	bytes	KEEP_CORE	Maior tamanho de pacote observado na direção backward. Feature comportamental de fluxo comum/compatível entre os datasets; preserva informação potencialmente transferível sem identificar diretamente o ambiente.
bwd_pkt_len_min	Bwd Packet Length Min	Bwd Pkt Len Min	bwd_pkt_len_min	3	bytes	KEEP_CORE	Menor tamanho de pacote observado na direção backward. Feature comportamental de fluxo comum/compatível entre os datasets; preserva informação potencialmente transferível sem identificar diretamente o ambiente.
bwd_pkt_len_mean	Bwd Packet Length Mean	Bwd Pkt Len Mean	bwd_pkt_len_mean	3	bytes	KEEP_CORE	Média do tamanho dos pacotes na direção backward. Feature comportamental de fluxo comum/compatível entre os datasets; preserva informação potencialmente transferível sem identificar diretamente o ambiente.
bwd_pkt_len_std	Bwd Packet Length Std	Bwd Pkt Len Std	bwd_pkt_len_std	3	bytes	KEEP_CORE	Desvio-padrão do tamanho dos pacotes na direção backward. Feature comportamental de fluxo comum/compatível entre os datasets; preserva informação potencialmente transferível sem identificar diretamente o ambiente.
pkt_len_min	Min Packet Length	Pkt Len Min	pkt_len_min	3	bytes	KEEP_CORE	Menor tamanho de pacote do fluxo. Feature comportamental de fluxo comum/compatível entre os datasets; preserva informação potencialmente transferível sem identificar diretamente o ambiente.
pkt_len_max	Max Packet Length	Pkt Len Max	pkt_len_max	3	bytes	KEEP_CORE	Maior tamanho de pacote do fluxo. Feature comportamental de fluxo comum/compatível entre os datasets; preserva informação potencialmente transferível sem identificar diretamente o ambiente.
pkt_len_mean	Packet Length Mean	Pkt Len Mean	pkt_len_mean	3	bytes	KEEP_CORE	Média do tamanho dos pacotes do fluxo. Feature comportamental de fluxo comum/compatível entre os datasets; preserva informação potencialmente transferível sem identificar diretamente o ambiente.
pkt_len_std	Packet Length Std	Pkt Len Std	pkt_len_std	3	bytes	KEEP_CORE	Desvio-padrão do tamanho dos pacotes do fluxo. Feature comportamental de fluxo comum/compatível entre os datasets; preserva informação potencialmente transferível sem identificar diretamente o ambiente.
pkt_len_var	Packet Length Variance	Pkt Len Var	pkt_len_var	3	bytes²	DERIVE	Variância do tamanho dos pacotes do fluxo. É matematicamente redundante com o desvio-padrão quando ambos usam a mesma convenção; no schema canônico pode ser derivada em vez de armazenada.
avg_packet_size	Average Packet Size	Pkt Size Avg	—	2	bytes	DROP	Tamanho médio dos pacotes do fluxo. Foi documentada como duplicata de Packet Length Mean em CIC-IDS2017; manter ambas acrescenta redundância sem nova informação.
fwd_segment_size_avg	Avg Fwd Segment Size	Fwd Seg Size Avg	—	2	bytes	DROP	Tamanho médio do segmento/pacote na direção forward. Foi documentada como duplicata de Fwd Packet Length Mean em CIC-IDS2017; o conceito já é representado pela média de tamanho forward.
bwd_segment_size_avg	Avg Bwd Segment Size	Bwd Seg Size Avg	—	2	bytes	DROP	Tamanho médio do segmento/pacote na direção backward. Foi documentada como duplicata de Bwd Packet Length Mean em CIC-IDS2017; o conceito já é representado pela média de tamanho backward.

Taxas

Canonical	CIC17	CSE18	LycoS18	Nº	Unidade	Decisão	Significado e justificativa
flow_bytes_per_s	Flow Bytes/s	Flow Byts/s	bytes_per_s	3	bytes	DERIVE	Taxa de bytes do fluxo por segundo. Pode ser recalculada de forma uniforme a partir de bytes totais e duração, evitando diferenças de implementação e valores Inf quando a duração é zero.
flow_packets_per_s	Flow Packets/s	Flow Pkts/s	pkt_per_s	3	pacotes/s	DERIVE	Taxa de pacotes do fluxo por segundo. Pode ser recalculada de forma uniforme a partir da contagem total de pacotes e duração; derivá-la reduz dependência do extrator.
fwd_packets_per_s	Fwd Packets/s	Fwd Pkts/s	fwd_pkt_per_s	3	pacotes/s	DERIVE	Taxa de pacotes forward por segundo. Taxa diretamente derivável da contagem de pacotes forward e duração; recomputar centralmente melhora consistência entre extratores.
bwd_packets_per_s	Bwd Packets/s	Bwd Pkts/s	bwd_pkt_per_s	3	pacotes/s	DERIVE	Taxa de pacotes backward por segundo. Taxa diretamente derivável da contagem de pacotes backward e duração; recomputar centralmente melhora consistência entre extratores.

Temporização / IAT

Canonical	CIC17	CSE18	LycoS18	Nº	Unidade	Decisão	Significado e justificativa
iat_mean	Flow IAT Mean	Flow IAT Mean	iat_mean	3	µs (CIC; validar LycoSTand)	KEEP_CORE	Média do tempo entre chegadas de pacotes no fluxo. Feature comportamental de fluxo comum/compatível entre os datasets; preserva informação potencialmente transferível sem identificar diretamente o ambiente.

Canonical	CIC17	CSE18	LycoS18	Nº	Unidade	Decisão	Significado e Justificativa
iat_std	Flow IAT Std	Flow IAT Std	iat_std	3	µs (CIC; validar LycoSTand)	KEEP_CORE	Desvio-padrão do tempo entre chegadas de pacotes no fluxo. Feature comportamental de fluxo comum/compatível entre os datasets; preserva informação potencialmente transferível sem identificar diretamente o ambiente.
iat_max	Flow IAT Max	Flow IAT Max	iat_max	3	µs (CIC; validar LycoSTand)	KEEP_CORE	Maior tempo entre chegadas de pacotes no fluxo. Feature comportamental de fluxo comum/compatível entre os datasets; preserva informação potencialmente transferível sem identificar diretamente o ambiente.
iat_min	Flow IAT Min	Flow IAT Min	iat_min	3	µs (CIC; validar LycoSTand)	KEEP_CORE	Menor tempo entre chegadas de pacotes no fluxo. Feature comportamental de fluxo comum/compatível entre os datasets; preserva informação potencialmente transferível sem identificar diretamente o ambiente.
fwd_iat_total	Fwd IAT Total	Fwd IAT Tot	fwd_iat_tot	3	µs (CIC; validar LycoSTand)	KEEP_CORE	Soma dos tempos entre chegadas na direção forward. Feature comportamental de fluxo comum/compatível entre os datasets; preserva informação potencialmente transferível sem identificar diretamente o ambiente.
fwd_iat_mean	Fwd IAT Mean	Fwd IAT Mean	fwd_iat_mean	3	µs (CIC; validar LycoSTand)	KEEP_CORE	Média dos tempos entre chegadas na direção forward. Feature comportamental de fluxo comum/compatível entre os datasets; preserva informação potencialmente transferível sem identificar diretamente o ambiente.
fwd_iat_std	Fwd IAT Std	Fwd IAT Std	fwd_iat_std	3	µs (CIC; validar LycoSTand)	KEEP_CORE	Desvio-padrão dos tempos entre chegadas na direção forward. Feature comportamental de fluxo comum/compatível entre os datasets; preserva informação potencialmente transferível sem identificar diretamente o ambiente.
fwd_iat_max	Fwd IAT Max	Fwd IAT Max	fwd_iat_max	3	µs (CIC; validar LycoSTand)	KEEP_CORE	Maior tempo entre chegadas na direção forward. Feature comportamental de fluxo comum/compatível entre os datasets; preserva informação potencialmente transferível sem identificar diretamente o ambiente.
fwd_iat_min	Fwd IAT Min	Fwd IAT Min	fwd_iat_min	3	µs (CIC; validar LycoSTand)	KEEP_CORE	Menor tempo entre chegadas na direção forward. Feature comportamental de fluxo comum/compatível entre os datasets; preserva informação potencialmente transferível sem identificar diretamente o ambiente.
bwd_iat_total	Bwd IAT Total	Bwd IAT Tot	bwd_iat_tot	3	µs (CIC; validar LycoSTand)	KEEP_CORE	Soma dos tempos entre chegadas na direção backward. Feature comportamental de fluxo comum/compatível entre os datasets; preserva informação potencialmente transferível sem identificar diretamente o ambiente.
bwd_iat_mean	Bwd IAT Mean	Bwd IAT Mean	bwd_iat_mean	3	µs (CIC; validar LycoSTand)	KEEP_CORE	Média dos tempos entre chegadas na direção backward. Feature comportamental de fluxo comum/compatível entre os datasets; preserva informação potencialmente transferível sem identificar diretamente o ambiente.
bwd_iat_std	Bwd IAT Std	Bwd IAT Std	bwd_iat_std	3	µs (CIC; validar LycoSTand)	KEEP_CORE	Desvio-padrão dos tempos entre chegadas na direção backward. Feature comportamental de fluxo comum/compatível entre os datasets; preserva informação potencialmente transferível sem identificar diretamente o ambiente.
bwd_iat_max	Bwd IAT Max	Bwd IAT Max	bwd_iat_max	3	µs (CIC; validar LycoSTand)	KEEP_CORE	Maior tempo entre chegadas na direção backward. Feature comportamental de fluxo comum/compatível entre os datasets; preserva informação potencialmente transferível sem identificar diretamente o ambiente.
bwd_iat_min	Bwd IAT Min	Bwd IAT Min	bwd_iat_min	3	µs (CIC; validar LycoSTand)	KEEP_CORE	Menor tempo entre chegadas na direção backward. Feature comportamental de fluxo comum/compatível entre os datasets; preserva informação potencialmente transferível sem identificar diretamente o ambiente.

Flags TCP

Canonical	CIC17	CSE18	LycoS18	Nº	Unidade	Decisão	Significado e Justificativa
fwd_flag_psh	Fwd PSH Flags	Fwd PSH Flags	fwd_flag_psh	3	contagem	KEEP_OPTIONAL	Quantidade de ocorrências da flag TCP PSH em pacotes forward. Pode carregar sinal comportamental útil, especialmente em tráfego TCP, mas é protocol-specific e algumas flags/direções podem ter variância muito baixa; deve ser mantida como opcional até o profiling.
bwd_flag_psh	Bwd PSH Flags	Bwd PSH Flags	bwd_flag_psh	3	contagem	KEEP_OPTIONAL	Quantidade de ocorrências da flag TCP PSH em pacotes backward. Pode carregar sinal comportamental útil, especialmente em tráfego TCP, mas é protocol-specific e algumas flags/direções podem ter variância muito baixa; deve ser mantida como opcional até o profiling.
fwd_flag_urg	Fwd URG Flags	Fwd URG Flags	fwd_flag_urg	3	contagem	KEEP_OPTIONAL	Quantidade de ocorrências da flag TCP URG em pacotes forward. Pode carregar sinal comportamental útil, especialmente em tráfego TCP, mas é protocol-specific e algumas flags/direções podem ter variância muito baixa; deve ser mantida como opcional até o profiling.
bwd_flag_urg	Bwd URG Flags	Bwd URG Flags	bwd_flag_urg	3	contagem	KEEP_OPTIONAL	Quantidade de ocorrências da flag TCP URG em pacotes backward. Pode carregar sinal comportamental útil, especialmente em tráfego TCP, mas é protocol-specific e algumas flags/direções podem ter variância muito baixa; deve ser mantida como opcional até o profiling.
flag_fin	FIN Flag Count	FIN Flag Cnt	flag_fin	3	contagem	KEEP_OPTIONAL	Número de pacotes com flag TCP FIN. Pode carregar sinal comportamental útil, especialmente em tráfego TCP, mas é protocol-specific e algumas flags/direções podem ter variância muito baixa; deve ser mantida como opcional até o profiling.
flag_syn	SYN Flag Count	SYN Flag Cnt	flag_SYN	3	contagem	KEEP_OPTIONAL	Número de pacotes com flag TCP SYN. Pode carregar sinal comportamental útil, especialmente em tráfego TCP, mas é protocol-specific e algumas flags/direções podem ter variância muito baixa; deve ser mantida como opcional até o profiling.

Canonical	CIC17	CSE18	LycoS18	Nº	Unidade	Decisão	Significado e justificativa
flag_rst	RST Flag Count	RST Flag Cnt	flag_rst	3	contagem	KEEP_OPTIONAL	Número de pacotes com flag TCP RST. Pode carregar sinal comportamental útil, especialmente em tráfego TCP, mas é protocol-specific e algumas flags/direções podem ter variância muito baixa; deve ser mantida como opcional até o profiling.
flag_psh	PSH Flag Count	PSH Flag Cnt	flag_psh	3	contagem	KEEP_OPTIONAL	Número de pacotes com flag TCP PSH. Pode carregar sinal comportamental útil, especialmente em tráfego TCP, mas é protocol-specific e algumas flags/direções podem ter variância muito baixa; deve ser mantida como opcional até o profiling.
flag_ack	ACK Flag Count	ACK Flag Cnt	flag_ack	3	contagem	KEEP_OPTIONAL	Número de pacotes com flag TCP ACK. Pode carregar sinal comportamental útil, especialmente em tráfego TCP, mas é protocol-specific e algumas flags/direções podem ter variância muito baixa; deve ser mantida como opcional até o profiling.
flag_urg	URG Flag Count	URG Flag Cnt	flag_urg	3	contagem	KEEP_OPTIONAL	Número de pacotes com flag TCP URG. Pode carregar sinal comportamental útil, especialmente em tráfego TCP, mas é protocol-specific e algumas flags/direções podem ter variância muito baixa; deve ser mantida como opcional até o profiling.
flag_cwe	CWE Flag Count	CWE Flag Count	flag_cwr	3	contagem	KEEP_OPTIONAL	Número de pacotes com flag TCP CWR/CWE conforme nomenclatura do dataset. Pode carregar sinal comportamental útil, especialmente em tráfego TCP, mas é protocol-specific e algumas flags/direções podem ter variância muito baixa; deve ser mantida como opcional até o profiling.
flag_ece	ECE Flag Count	ECE Flag Cnt	flag_ece	3	contagem	KEEP_OPTIONAL	Número de pacotes com flag TCP ECE. Pode carregar sinal comportamental útil, especialmente em tráfego TCP, mas é protocol-specific e algumas flags/direções podem ter variância muito baixa; deve ser mantida como opcional até o profiling.

Cabeçalhos

Canonical	CIC17	CSE18	LycoS18	Nº	Unidade	Decisão	Significado e justificativa
fwd_header_len_total	Fwd Header Length	Fwd Header Len	fwd_pkt_hdr_len_tot	3	bytes	KEEP_OPTIONAL	Total de bytes de cabeçalho observados na direção forward. Resume volume de cabeçalhos e pode conter sinal estrutural, porém é mais sensível a detalhes do extrator/protocolo que contagens e tamanhos fundamentais.
bwd_header_len_total	Bwd Header Length	Bwd Header Len	bwd_pkt_hdr_len_tot	3	bytes	KEEP_OPTIONAL	Total de bytes de cabeçalho observados na direção backward. Resume volume de cabeçalhos e pode conter sinal estrutural, porém é mais sensível a detalhes do extrator/protocolo que contagens e tamanhos fundamentais.
bwd_header_len_min	—	—	bwd_pkt_hdr_len_min	1	bytes	INVESTIGATE	Menor quantidade de bytes de cabeçalho observada em pacotes backward. É uma feature válida do LycoStand, mas não possui correspondente explícito no schema CIC/CSE usado no artigo-base; não deve entrar no core de três bases sem alternativa equivalente.

Razões

Canonical	CIC17	CSE18	LycoS18	Nº	Unidade	Decisão	Significado e justificativa
down_up_ratio	Down/Up Ratio	Down/Up Ratio	down_up_ratio	3	adimensional	DERIVE	Razão entre tráfego downstream e upstream. É uma razão de grandezas já representadas por contagens/bytes; derivá-la permite definir explicitamente o comportamento quando o denominador é zero.

Bulk

Canonical	CIC17	CSE18	LycoS18	Nº	Unidade	Decisão	Significado e justificativa
fwd_bulk_bytes_mean	Fwd Avg Bytes/Bulk	Fwd Byts/b Avg	fwd_bulk_bytes_mean	3	bytes	INVESTIGATE	Média de bytes por bulk na direção forward. A feature existe nos três esquemas mapeados, mas métricas de bulk frequentemente apresentam zero variance/baixa utilidade em CICIDS2017; a decisão deve ser baseada no profiling completo e na equivalência entre extratores.
fwd_bulk_pkt_mean	Fwd Avg Packets/Bulk	Fwd Pkts/b Avg	fwd_bulk_pkt_mean	3	contagem	INVESTIGATE	Média de pacotes por bulk na direção forward. A feature existe nos três esquemas mapeados, mas métricas de bulk frequentemente apresentam zero variance/baixa utilidade em CICIDS2017; a decisão deve ser baseada no profiling completo e na equivalência entre extratores.
fwd_bulk_rate_mean	Fwd Avg Bulk Rate	Fwd Blk Rate Avg	fwd_bulk_rate_mean	3	taxa (verificar definição exata)	INVESTIGATE	Taxa média de bulk na direção forward. A feature existe nos três esquemas mapeados, mas métricas de bulk frequentemente apresentam zero variance/baixa utilidade em CICIDS2017; a decisão deve ser baseada no profiling completo e na equivalência entre extratores.
bwd_bulk_bytes_mean	Bwd Avg Bytes/Bulk	Bwd Byts/b Avg	bwd_bulk_bytes_mean	3	bytes	INVESTIGATE	Média de bytes por bulk na direção backward. A feature existe nos três esquemas mapeados, mas métricas de bulk frequentemente apresentam zero variance/baixa utilidade em CICIDS2017; a decisão deve ser baseada no profiling completo e na equivalência entre extratores.
bwd_bulk_pkt_mean	Bwd Avg Packets/Bulk	Bwd Pkts/b Avg	bwd_bulk_pkt_mean	3	contagem	INVESTIGATE	Média de pacotes por bulk na direção backward. A feature existe nos três esquemas mapeados, mas métricas de bulk frequentemente apresentam zero variance/baixa utilidade em CICIDS2017; a decisão deve ser baseada no profiling completo e na equivalência entre extratores.

Canonical	CIC17	CSE18	LycoS18	Nº	Unidade	Decisão	Significado e justificativa
bwd_bulk_rate_mean	Bwd Avg Bulk Rate	Bwd Blk Rate Avg	bwd_bulk_rate_mean	3	taxa (verificar definição exata)	INVESTIGATE	Taxa média de bulk na direção backward. A feature existe nos três esquemas mapeados, mas métricas de bulk frequentemente apresentam zero variance/baixa utilidade em CICIDS2017; a decisão deve ser baseada no profiling completo e na equivalência entre extratores.

Subflow

Canonical	CIC17	CSE18	LycoS18	Nº	Unidade	Decisão	Significado e justificativa
fwd_subflow_pkt_mean	Subflow Fwd Packets	Subflow Fwd Pkts	fwd_subflow_pkt_mean	3	contagem	INVESTIGATE	Média/contagem de pacotes forward por subfluxo, conforme extrator. Pode representar comportamento por subfluxos, mas há evidências de forte redundância/equivalência com totais em versões do CICFlowMeter; deve ser validada por igualdade/correlação nos dados completos.
fwd_subflow_bytes_mean	Subflow Fwd Bytes	Subflow Fwd Byts	fwd_subflow_bytes_mean	3	bytes	INVESTIGATE	Média/contagem de bytes forward por subfluxo, conforme extrator. Pode representar comportamento por subfluxos, mas há evidências de forte redundância/equivalência com totais em versões do CICFlowMeter; deve ser validada por igualdade/correlação nos dados completos.
bwd_subflow_pkt_mean	Subflow Bwd Packets	Subflow Bwd Pkts	bwd_subflow_pkt_mean	3	contagem	INVESTIGATE	Média/contagem de pacotes backward por subfluxo, conforme extrator. Pode representar comportamento por subfluxos, mas há evidências de forte redundância/equivalência com totais em versões do CICFlowMeter; deve ser validada por igualdade/correlação nos dados completos.
bwd_subflow_bytes_mean	Subflow Bwd Bytes	Subflow Bwd Byts	bwd_subflow_bytes_mean	3	bytes	INVESTIGATE	Média/contagem de bytes backward por subfluxo, conforme extrator. Pode representar comportamento por subfluxos, mas há evidências de forte redundância/equivalência com totais em versões do CICFlowMeter; deve ser validada por igualdade/correlação nos dados completos.

Janela TCP

Canonical	CIC17	CSE18	LycoS18	Nº	Unidade	Decisão	Significado e justificativa
fwd_tcp_init_win_bytes	Init_Win_bytes_forward	Init Fwd Win Byts	fwd_tcp_init_win_bytes	3	bytes	KEEP_OPTIONAL	Valor da janela TCP inicial observado na direção forward. A janela TCP inicial pode ser discriminativa e é comum aos três esquemas, porém é TCP-specific e usa valores sentinela em alguns arquivos; requer tratamento sem confundir sentinela com zero.
bwd_tcp_init_win_bytes	Init_Win_bytes_backward	Init Bwd Win Byts	bwd_tcp_init_win_bytes	3	bytes	KEEP_OPTIONAL	Valor da janela TCP inicial observado na direção backward. A janela TCP inicial pode ser discriminativa e é comum aos três esquemas, porém é TCP-specific e usa valores sentinela em alguns arquivos; requer tratamento sem confundir sentinela com zero.

TCP / payload e segmento

Canonical	CIC17	CSE18	LycoS18	Nº	Unidade	Decisão	Significado e justificativa
fwd_non_empty_pkt_count	act_data_pkt_fwd	Fwd Act Data Pkts	fwd_non_empty_pkt_cnt	3	contagem	INVESTIGATE	Quantidade de pacotes forward com pelo menos 1 byte de payload TCP. O CICFlowMeter define a contagem de pacotes forward com pelo menos 1 byte de payload; LycoS possui fwd_non_empty_pkt_cnt com descrição equivalente, mas o mapeamento do artigo-base não os alinhou explicitamente.
fwd_segment_size_min	min_seg_size_forward	Fwd Seg Size Min	fwd_pkt_hdr_len_min	3	bytes	INVESTIGATE	Menor tamanho de segmento observado na direção forward. CICFlowMeter fala em menor tamanho de segmento forward, enquanto LycoS expõe menor comprimento de cabeçalho forward; os nomes próximos não bastam para afirmar equivalência.
bwd_non_empty_pkt_count	—	—	bwd_non_empty_pkt_cnt	1	contagem	INVESTIGATE	Número de pacotes backward com pelo menos 1 byte de payload TCP. Pode representar presença de dados efetivos no sentido backward, porém é LycoS-only nos samples e não existe equivalente explícito no conjunto CIC/CSE analisado.

Atividade / ociosidade

Canonical	CIC17	CSE18	LycoS18	Nº	Unidade	Decisão	Significado e justificativa
active_mean	Active Mean	Active Mean	active_mean	3	µs (CIC; validar LycoSTand)	KEEP_CORE	Média da duração dos períodos ativos do fluxo. Caracteriza a dinâmica temporal de atividade/ociosidade do fluxo; é mapeada entre os três datasets e pode capturar padrões comportamentais sem depender de identificadores.
active_std	Active Std	Active Std	active_std	3	µs (CIC; validar LycoSTand)	KEEP_CORE	Desvio-padrão da duração dos períodos ativos do fluxo. Caracteriza a dinâmica temporal de atividade/ociosidade do fluxo; é mapeada entre os três datasets e pode capturar padrões comportamentais sem depender de identificadores.
active_max	Active Max	Active Max	active_max	3	µs (CIC; validar LycoSTand)	KEEP_CORE	Maior duração de período ativo do fluxo. Caracteriza a dinâmica temporal de atividade/ociosidade do fluxo; é mapeada entre os três datasets e pode capturar padrões comportamentais sem depender de identificadores.

Canonical	CIC17	CSE18	LycoS18	Nº	Unidade	Decisão	Significado e justificativa
active_min	Active Min	Active Min	active_min	3	µs (CIC; validar LycoSTand)	KEEP_CORE	Menor duração de período ativo do fluxo. Caracteriza a dinâmica temporal de atividade/ociosidade do fluxo; é mapeada entre os três datasets e pode capturar padrões comportamentais sem depender de identificadores.
idle_mean	Idle Mean	Idle Mean	idle_mean	3	µs (CIC; validar LycoSTand)	KEEP_CORE	Média da duração dos períodos ociosos do fluxo. Caracteriza a dinâmica temporal de atividade/ociosidade do fluxo; é mapeada entre os três datasets e pode capturar padrões comportamentais sem depender de identificadores.
idle_std	Idle Std	Idle Std	idle_std	3	µs (CIC; validar LycoSTand)	KEEP_CORE	Desvio-padrão da duração dos períodos ociosos do fluxo. Caracteriza a dinâmica temporal de atividade/ociosidade do fluxo; é mapeada entre os três datasets e pode capturar padrões comportamentais sem depender de identificadores.
idle_max	Idle Max	Idle Max	idle_max	3	µs (CIC; validar LycoSTand)	KEEP_CORE	Maior duração de período ocioso do fluxo. Caracteriza a dinâmica temporal de atividade/ociosidade do fluxo; é mapeada entre os três datasets e pode capturar padrões comportamentais sem depender de identificadores.
idle_min	Idle Min	Idle Min	idle_min	3	µs (CIC; validar LycoSTand)	KEEP_CORE	Menor duração de período ocioso do fluxo. Caracteriza a dinâmica temporal de atividade/ociosidade do fluxo; é mapeada entre os três datasets e pode capturar padrões comportamentais sem depender de identificadores.

Alvo

Canonical	CIC17	CSE18	LycoS18	Nº	Unidade	Decisão	Significado e justificativa
label	Label	Label	label	3	categoria	TARGET	Rótulo de classe do fluxo (benigno ou categoria de ataque). É a variável-alvo, não uma feature preditora. Precisa de taxonomia comum entre datasets e nunca deve entrar no vetor X do modelo.

Qualidade de dados

Canonical	CIC17	CSE18	LycoS18	Nº	Unidade	Decisão	Significado e justificativa
fwd_header_len_duplicate_raw	Fwd Header Length (2ª ocorrência)	—	—	1	bytes	DROP	Segunda ocorrência duplicada de Fwd Header Length no CSV CIC-IDS2017/ISCX. Duplicata documentada; contém a mesma informação da feature Fwd Header Length e não representa um conceito canônico adicional.

5. Colunas adicionais em variantes de schema

Os samples não capturam todas as variantes internas. O CSE-CIC-IDS2018 possui arquivos com colunas adicionais de identificação. A política preliminar é removê-las do vetor preditivo e manter, se necessário, apenas como metadado de rastreabilidade fora do modelo.

Feature	Onde aparece	Decisão	Justificativa	Fontes
Flow ID	CSE-CIC-IDS2018 (alguns CSVs) / versões completas CIC	DROP	Identificador quase único do fluxo; favorece memorização e não generaliza.	S3; S7
Src IP	CSE-CIC-IDS2018 (alguns CSVs) / versões completas CIC	DROP	Identificador/topologia do ambiente; alto risco de shortcut/leakage.	S3; S7
Dst IP	CSE-CIC-IDS2018 (alguns CSVs) / versões completas CIC	DROP	Identificador/topologia do ambiente; pode memorizar vítima/host do laboratório.	S3; S7
Src Port	CSE-CIC-IDS2018 (alguns CSVs) / versões completas CIC	DROP	Frequentemente efêmera e dependente da sessão; pouco adequada como feature geral cross-dataset.	S3; S7

6. Próximas validações antes de congelar a DSL

- Profiler completo por feature: missing, NaN, $\pm$ Inf, % zero, % negativos, min, max, média, desvio, nº de únicos.
- Testes de redundância/equivalência: pkt_len_mean vs avg_packet_size; médias forward/backward vs segment size; subflow vs totais; variância vs std².
- Inspeção do código dos extratores para fwd_non_empty_pkt_cnt ↔ Fwd Act Data Pkts e fwd_pkt_hdr_len_min ↔ Fwd Seg Size Min.
- Definição explícita das unidades temporais e da política para duração zero antes de derivar taxas.
- Experimentos de ablação para dst_port, ip_protocol, flags TCP e TCP initial window.
- Harmonização da taxonomia de labels em uma etapa separada do schema de features.

7. Fontes principais

S1 — CICFlowMeter - ReadMe / feature definitions

<https://github.com/ahlashkari/CICFlowMeter/blob/master/ReadMe.txt>

Uso: Definições e unidades das features CICFlowMeter; direção forward/backward.

S2 — CIC-IDS2017 official dataset page (UNB/CIC)

<https://www.unb.ca/cic/datasets/ids-2017.html>

Uso: Contexto, dias de captura, ataques e uso do CICFlowMeter.

S3 — CSE-CIC-IDS2018 official dataset page (UNB/CIC)

<https://www.unb.ca/cic/datasets/ids-2018.html>

Uso: Contexto, infraestrutura, ataques, CICFlowMeter-V3 e lista de features.

S4 — Rosay et al. - Network Intrusion Detection: A Comprehensive Analysis of CIC-IDS2017

<https://www.scitepress.org/Papers/2022/107740/107740.pdf>

Uso: Problemas de integridade, duplicações, erros de cálculo, protocolo e LycoSTand.

S5 — LycoS-Unicas-IDS2018 official GitHub repository

<https://github.com/MarcoCantone/LycoS-Unicas-IDS2018>

Uso: Origem do LycoS18, 13,691,268 registros, 77 features + label e classes.

S6 — Cantone, Marrocco & Bria (2024) - Cross-Dataset Generalization Study

<https://iris.unicas.it/retrieve/a40146bd-61d7-4a77-98c7-cf72f480c839/2024%20-%20Machine%20Learning%20in%20Network%20Intrusion%20Detection%20-%20A%20Cross-Dataset%20Generalization%20Study.pdf>

Uso: Generalização cross-dataset, mRMR, interdependência/redundância e heterogeneidade.

S7 — Cantone et al. - preprocess_dataset.py

https://raw.githubusercontent.com/MarcoCantone/NIDS_cross-dataset_generalization/main/preprocess_dataset.py

Uso: Mapeamento explícito CIC/CSE/LycoS, drops e harmonização de labels.

S8 — Sarhan, Layeghy & Portmann - Towards a Standard Feature Set for NIDS Datasets

<https://arxiv.org/abs/2101.11315>

Uso: Motivação para conjunto comum de features e referência NetFlow 12/43 features.

S9 — Evaluation of Machine Learning Techniques for Traffic Flow-Based Intrusion Detection

<https://www.mdpi.com/1424-8220/22/23/9326>

Uso: Evidência de Destination Port como atalho e decisão de removê-la para maior generalidade.

S10 — LYCOS-IDS2017 / LycoSTand official site

<https://lycos-ids.univ-lemans.fr/>

Uso: Descrição do LycoSTand, origem e relação com CIC-IDS2017.

S11 — Machine Learning-Based Open-Source Framework for Real-Time NIDS (2026)

<https://ietresearch.onlinelibrary.wiley.com/doi/10.1049/ise2/1954901>

Uso: Exemplo recente de remoção de features zero-variance, incluindo métricas bulk/flags.

S12 — UniQL repository - samples usados neste TCC

<https://github.com/phramos07/uniql/tree/main/data/samples>

Uso: Headers reais dos três samples analisados.

S13 — LycoSTand feature descriptions (doctoral thesis excerpt)

https://www.researchgate.net/publication/367156456_Detection_d%27intrusions_dans_les_objets_connectes_par_des_techniques_d%27apprentissage_automatique_etude_dans_les_domaines_de_l%27education_et_des_voitures_connectees

Uso: Descrições de features LycoSTand como non-empty packet count e header length min.